# wb km2

April 7, 2022

# 1 WB - milestone 2 - inżynieria cech i wstępne modelowanie

## 1.1 physioNet dataset

## 1.1.1 Autorzy:

Paulina Jaszczuk Jędrzej Sokołowski Filip Szympliński

```
[]: import pandas as pd
     import numpy as np
     import matplotlib.pyplot as plt
     import seaborn as sns
     import copy
     from sklearn import preprocessing
     from sklearn.model_selection import train_test_split
     import xgboost as xgb
     from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor, u
     \hookrightarrowBaggingClassifier
     from sklearn.tree import DecisionTreeClassifier
     from tqdm.notebook import tqdm
     from sklearn.metrics import mean_squared_error as MSE
     from sklearn.metrics import roc_auc_score, accuracy_score, f1_score, roc_curve, u

¬r2_score

     import warnings
     warnings.filterwarnings('ignore')
     # ustawia domyślną wielkość wykresów
     plt.rcParams['figure.figsize'] = (12,8)
     # to samo tylko dla tekstu
     plt.rcParams['font.size'] = 16
```

# 1.2 Import danych i poglądowe informacje

Zbiór danych medycznych physioNet opisujący pacjentów z oddziałów kariochirurgicznych.

```
[]: data = pd.read_csv("patients_data_ready.csv", sep=",", index_col=[0])
[]: data.rename(columns = {"MechVent_max" : "MechVent"}, inplace = True)
    data.info()
```

<class 'pandas.core.frame.DataFrame'>
Int64Index: 3855 entries, 0 to 3999
Data columns (total 82 columns):

Data	COLUMNIS (COCAL	OZ COTUMIS).	
#	Column	Non-Null Count	Dtype
0	Age	3855 non-null	float64
1	Gender	3855 non-null	float64
2	Height	3855 non-null	float64
3	ICUType	3855 non-null	float64
4	Weight	3855 non-null	float64
5	MAP_mean	3855 non-null	float64
6	MAP_max	3855 non-null	float64
7	MAP_min	3855 non-null	float64
8	HCT_mean	3855 non-null	float64
9	HCT_max	3855 non-null	float64
10	HCT_min	3855 non-null	float64
11	SysABP_mean	3855 non-null	float64
12	SysABP_max	3855 non-null	float64
13	SysABP_min	3855 non-null	float64
14	${\tt NIDiasABP\_mean}$	3855 non-null	float64
15	NIDiasABP_max	3855 non-null	float64
16	NIDiasABP_min	3855 non-null	float64
17	Lactate_mean	3855 non-null	float64
18	Lactate_max	3855 non-null	float64
19	Lactate_min	3855 non-null	float64
20	HR_mean	3855 non-null	float64
21	HR_max	3855 non-null	float64
22	HR_min	3855 non-null	float64
23	FiO2_mean	3855 non-null	float64
24	FiO2_max	3855 non-null	float64
25	FiO2_min	3855 non-null	float64
26	Urine_mean	3855 non-null	float64
27	Urine_max	3855 non-null	float64
28	Urine_min	3855 non-null	float64
29	BUN_mean	3855 non-null	float64
30	BUN_max	3855 non-null	float64
31	BUN_min	3855 non-null	float64
32	Mg_mean	3855 non-null	float64
33	Mg_max	3855 non-null	float64

34	Mg_min		non-null	float64
35	Na_mean		non-null	float64
36	Na_max	3855	non-null	float64
37	Na_min	3855	non-null	float64
38	MechVent	3855	non-null	float64
39	K_mean	3855	non-null	float64
40	K_max	3855	non-null	float64
41	K_min	3855	non-null	float64
42	PaCO2_mean	3855	non-null	float64
43	PaCO2_max	3855	non-null	float64
44	PaCO2_min	3855	non-null	float64
45	pH_mean	3855	non-null	float64
46	pH_max	3855	non-null	float64
47	pH_min	3855	non-null	float64
48	GCS_mean	3855	non-null	float64
49	GCS_max	3855	non-null	float64
50	GCS_min	3855	non-null	float64
51	Platelets_mean	3855	non-null	float64
52	Platelets_max	3855	non-null	float64
53	Platelets_min	3855		float64
54	Temp_mean		non-null	float64
55	Temp_max	3855	non-null	float64
56	Temp_min	3855		float64
57	NISysABP_mean	3855		float64
58	NISysABP_max		non-null	float64
59	NISysABP_min	3855		float64
60	Pa02_mean	3855		float64
61	PaO2_max	3855		float64
62	PaO2_min		non-null	float64
63	Glucose_mean		non-null	float64
64	Glucose_max	3855		float64
65	Glucose_min	3855		float64
66	Creatinine_mean	3855	non-null	float64
67	_		non-null	float64
68	Creatinine_max Creatinine_min			float64
69	DiasABP_mean		non-null	float64
70	<del>-</del>		non-null	float64
	DiasABP_max		non-null	
71	DiasABP_min		non-null	float64
72	WBC_mean	3855		float64
73	WBC_max		non-null	float64
74	WBC_min		non-null	float64
75 76	HCO3_mean		non-null	float64
76	HCO3_max	3855		float64
77	HCO3_min		non-null	float64
78	NIMAP_mean		non-null	float64
79	NIMAP_max		non-null	float64
80	NIMAP_min	3855		float64
81	Survived	პԾ55	non-null	int64

```
dtypes: float64(81), int64(1) memory usage: 2.4 MB
```

Dane zawierają 5 cech statycznych (Age, Gender, Height, Weight, ICUType - rodzaj oddziału, na którym przebywał pacjent) oraz 75 cech dynamicznych, mierzonych co najmniej jednokrotnie. Wśród nich jest jedna zmienna binarna - MechVent - kolumna odpowiadająca informacji, czy pacjent został poddany wentylacji z użyciem respiratora. Zmienne dynamiczne, oprócz MechVent wyrażone są przez minimum, średnią i maximum z wszystkich pomiarów dla danego pacjenta. Zmienna celu - Survived - jest binarna (1, jeśli pacjent przeżył i 0, jeśli nie przeżył).


# 1.3 Inżynieria danych

Wszystkie braki danych zostały przez nas usunięte lub zaimputowane na poprzednim etapie pracy. Dane nie zawierają wartości kategorycznych, które należałoby zakodować.

## 1.3.1 Outliery

Na poprzednim etapie prac zauważyliśmy, że wśród danych występują liczne outliery, jednak z racji na medyczny charakter danych, mogą one stanowić ważną informację w procesie modelowania i samej predykcji.


```
[]: #boxplot liczby outlierów z podziałem na zmienną celu
sns.boxplot( x=data['Survived'], y=data['n_outliers'])
plt.show()
```



Jak widać, pacjenci, którzy nie przeżyli zdecydowanie częściej mieli skrajnie wysokie lub skrajnie niskie wartości odczytów medycznych - wśród ich danych jest wyraźnie więcej outlierów. Potwierdza to nasze przypuszczenie, że nie możemy pozbyć się tych informacji z naszego zbioru danych.

## 1.3.2 Przekształcenia danych


Na poprzednim etapie prac zidentyfikowaliśmy kilka zmiennych, których rozkłady mocno skupiają się w pobliżu zera.



Postanowiliśmy stworzyć drugą ramkę danych, w której dane kolumny zlogarytmujemy. Dalsze prace - modelowanie - będziemy wykonywać na obu ramkach danych i porównamy wyniki.

```
[]: #tworzymy drugą ramkę ze zlogarytmowanymi wyżej wymienionymi kolumnami data_log = copy.deepcopy(data) data_log[cols_to_log] = data_log[cols_to_log].apply(lambda x: np.log1p(x), → axis=1)
```

```
[]: data_log[cols_to_log].hist(bins = 20, figsize=(20, 14))
plt.show()
```



Rozkłady zmiennych zlogarytmowanych prezentują się znacznie bardziej informatywnie.

## 1.4 Wstępne modelowanie

Nasze dane są mocno niezbalansowane - pacjentów, którzy zmarli jest zdecydawanie mniej niż tych, którzy przeżyli (stosunek mniej więcej 1:6). Jednocześnie to właśnie właściwa predykcja przypadków śmierci interesuje nas najbardziej. Między innymi z tego właśnie powodu zdecydowaliśmy się zastosować kilka metryk, a część z nich wyliczaliśmy oddzielnie dla obu klas - metryka ważona, z racji niezbalansowania klas, mogłaby być mocno zawyżona.

Do ocenienia działań modelu zastosowaliśmy metryki F1 score - osobno dla każdej klasy a także ważony, a także precision i recall oddzielnie dla każdej klasy. W przypadku metryk liczonych osobno dla obu klas, pierwsza wartość dotyczy pacjentów, którzy zmarli, zaś druga tych, którzy przeżyli.

```
def show_model_metrics(model, X, y):
    y_pred = model.predict(X)
    print(f"F1 score: {f1_score(y, y_pred, average=None)}")
    print(f"F1 score micro: {f1_score(y, y_pred, average='micro')}")
    print(f"F1 score weighted: {f1_score(y, y_pred, average='weighted')}")
    print(f"Precision score: {precision_score(y, y_pred, average=None)}")
    print(f"Recall score: {recall_score(y, y_pred, average=None)}")
```

```
[]: from sklearn.model_selection import train_test_split
     from sklearn.metrics import roc_auc_score, accuracy_score, f1_score, roc_curve, u
     →confusion_matrix, precision_score, recall_score
     y = data["Survived"]
     X = data.drop("Survived", axis= 1)
     #podział na train/val/test zbioru oryginalnego
     X_train_val, X_test, y_train_val, y_test = train_test_split(X, y,_
     →random_state=420, test_size=0.2)
     X_train, X_val, y_train, y_val = train_test_split(X_train_val, y_train_val, u
     →random_state=420, test_size=0.125)
[]: y_log = data_log["Survived"]
     X_log = data_log.drop("Survived", axis= 1)
     #podział na train/val/test zbioru z kolumnami zlogarytmowanymi
     X_train_val_log, X_test_log, y_train_val_log, y_test_log =_
     →train_test_split(X_log, y_log, random_state=420, test_size=0.2)
     X_train_log, X_val_log, y_train_log, y_val_log =_
     →train_test_split(X_train_val_log, y_train_val_log, random_state=420,__
     →test_size=0.125)
    1.4.1 XGBoost - dane po tranformacjach logarytmicznych
[]: xgb_clf = xgb.XGBClassifier(random_state=1,
                         booster='gbtree',
                         use_label_encoder=False,
     xgb_clf.fit(X_train_log, y_train_log)
[]: XGBClassifier(random state=1, use label encoder=False)
[]: y_pred = xgb_clf.predict(X_val_log)
     print(accuracy_score(y_val_log, y_pred, normalize=True))
     show_model_metrics(xgb_clf, X_val_log, y_val_log)
    0.8626943005181347
    F1 score: [0.2739726 0.9241774]
    F1 score micro: 0.8626943005181347
    F1 score weighted: 0.8281626987886429
    Precision score: [0.625
                                 0.872972971
    Recall score: [0.1754386 0.98176292]
[]: xgb_clf = xgb.XGBClassifier(random_state=42,
                         booster='gbtree',
                         use_label_encoder=False,
```

```
learning_rate=0.01, n_estimators=20
     xgb_clf.fit(X_train_log, y_train_log)
[]: XGBClassifier(learning_rate=0.01, n_estimators=20, random_state=42,
                   use_label_encoder=False)
[]: y_pred = xgb_clf.predict(X_val_log)
     print(accuracy_score(y_val_log, y_pred, normalize=True))
     show_model_metrics(xgb_clf, X_val_log, y_val_log)
    0.8575129533678757
    F1 score: [0.20289855 0.92176387]
    F1 score micro: 0.8575129533678757
    F1 score weighted: 0.8156101822171706
    Precision score: [0.58333333 0.86631016]
    Recall score: [0.12280702 0.98480243]
[]: xgb_clf = xgb.XGBClassifier(random_state=42,
                         booster='gbtree',
                         use_label_encoder=False,
                         learning_rate=0.5, n_estimators=50
     xgb_clf.fit(X_train, y_train)
[]: XGBClassifier(learning_rate=0.5, n_estimators=50, random_state=42,
                   use label encoder=False)
[]: y_pred = xgb_clf.predict(X_val_log)
     print(accuracy_score(y_val_log, y_pred, normalize=True))
     show_model_metrics(xgb_clf, X_val_log, y_val_log)
    0.8575129533678757
    F1 score: [0.17910448 0.92198582]
    F1 score micro: 0.8575129533678757
    F1 score weighted: 0.8122857216508134
    Precision score: [0.6
                                0.8643617]
    Recall score: [0.10526316 0.98784195]
    1.4.2 XGBoost - dane bez tranformacjacji logarytmicznych
[]: xgb_clf = xgb.XGBClassifier(random_state=1,
                         booster='gbtree',
                         use_label_encoder=False,
     xgb_clf.fit(X_train, y_train)
```

```
[]: XGBClassifier(random_state=1, use_label_encoder=False)
[]: y_pred = xgb_clf.predict(X_val)
     print(accuracy_score(y_val, y_pred, normalize=True))
     show_model_metrics(xgb_clf, X_val, y_val)
    0.8626943005181347
    F1 score: [0.2739726 0.9241774]
    F1 score micro: 0.8626943005181347
    F1 score weighted: 0.8281626987886429
    Precision score: [0.625]
                                 0.87297297]
    Recall score: [0.1754386 0.98176292]
[]: xgb_clf = xgb.XGBClassifier(random_state=42,
                         booster='gbtree',
                         use_label_encoder=False,
                         learning_rate=0.01, n_estimators=20
     xgb_clf.fit(X_train, y_train)
[]: XGBClassifier(learning_rate=0.01, n_estimators=20, random_state=42,
                   use_label_encoder=False)
[]: y_pred = xgb_clf.predict(X_val)
     print(accuracy_score(y_val, y_pred, normalize=True))
     show_model_metrics(xgb_clf, X_val, y_val)
    0.8575129533678757
    F1 score: [0.20289855 0.92176387]
    F1 score micro: 0.8575129533678757
    F1 score weighted: 0.8156101822171706
    Precision score: [0.58333333 0.86631016]
    Recall score: [0.12280702 0.98480243]
[]: xgb_clf = xgb.XGBClassifier(random_state=42,
                         booster='gbtree',
                         use_label_encoder=False,
                         learning_rate=0.5, n_estimators=50
     xgb_clf.fit(X_train, y_train)
[]: XGBClassifier(learning_rate=0.5, n_estimators=50, random_state=42,
                  use_label_encoder=False)
[ ]: y_pred = xgb_clf.predict(X_val)
     print(accuracy_score(y_val, y_pred, normalize=True))
     show_model_metrics(xgb_clf, X_val, y_val)
```

#### 0.8678756476683938

F1 score: [0.38554217 0.92597968] F1 score micro: 0.8678756476683938 F1 score weighted: 0.846174141356631 Precision score: [0.61538462 0.88611111] Recall score: [0.28070175 0.96960486]

## 1.4.3 Random Forest - dane po tranformacjach logarytmicznych

```
[]: rForest = RandomForestClassifier()
    rForest.fit(X_train_log, y_train_log)

y_pred = rForest.predict(X_val_log)
    print(accuracy_score(y_val_log, y_pred, normalize=True))
    show_model_metrics(rForest, X_val_log, y_val_log)
```

#### 0.8575129533678757

F1 score: [0.12698413 0.92242595] F1 score micro: 0.8575129533678757 F1 score weighted: 0.8049643353910475 Precision score: [0.66666667 0.86052632] Recall score: [0.07017544 0.99392097]

```
[]: rForest = RandomForestClassifier(criterion='entropy')
    rForest.fit(X_train_log, y_train_log)

y_pred = rForest.predict(X_val_log)
    print(accuracy_score(y_val_log, y_pred, normalize=True))
    show_model_metrics(rForest, X_val_log, y_val_log)
```

### 0.8601036269430051

F1 score: [0.12903226 0.92394366] F1 score micro: 0.8601036269430051 F1 score weighted: 0.8065603717575384 Precision score: [0.8 0.86089239] Recall score: [0.07017544 0.99696049]

```
[]: rForest = RandomForestClassifier(n_estimators=300)
    rForest.fit(X_train_log, y_train_log)

    y_pred = rForest.predict(X_val_log)
    print(accuracy_score(y_val_log, y_pred, normalize=True))
    show_model_metrics(rForest, X_val_log, y_val_log)
```

#### 0.8575129533678757

F1 score: [0.12698413 0.92242595] F1 score micro: 0.8575129533678757 F1 score weighted: 0.8049643353910475 Precision score: [0.66666667 0.86052632] Recall score: [0.07017544 0.99392097]

```
[]: rForest = RandomForestClassifier(n_estimators=30)
    rForest.fit(X_train_log, y_train_log)

y_pred = rForest.predict(X_val_log)
    print(accuracy_score(y_val_log, y_pred, normalize=True))
    show_model_metrics(rForest, X_val_log, y_val_log)
```

#### 0.8626943005181347

F1 score: [0.23188406 0.92460882] F1 score micro: 0.8626943005181347 F1 score weighted: 0.8223152665001824 Precision score: [0.66666667 0.86898396] Recall score: [0.14035088 0.98784195]

## 1.4.4 Random Forest - dane bez tranformacji logarytmicznych

```
[]: rForest = RandomForestClassifier()
    rForest.fit(X_train, y_train)

y_pred = rForest.predict(X_val)
    print(accuracy_score(y_val, y_pred, normalize=True))
    show_model_metrics(rForest, X_val, y_val)
```

#### 0.8575129533678757

F1 score: [0.17910448 0.92198582]
F1 score micro: 0.8575129533678757
F1 score weighted: 0.8122857216508134
Precision score: [0.6 0.8643617]
Recall score: [0.10526316 0.98784195]

```
[]: rForest = RandomForestClassifier(criterion='entropy')
rForest.fit(X_train, y_train)

y_pred = rForest.predict(X_val)
print(accuracy_score(y_val, y_pred, normalize=True))
show_model_metrics(rForest, X_val, y_val)
```

### 0.8549222797927462

F1 score: [0.09677419 0.92112676]
F1 score micro: 0.854922279792746
F1 score weighted: 0.7993959410818916
Precision score: [0.6 0.85826772]
Recall score: [0.05263158 0.99392097]

```
[]: rForest = RandomForestClassifier(n_estimators=300)
     rForest.fit(X_train, y_train)
     y_pred = rForest.predict(X_val)
     print(accuracy_score(y_val, y_pred, normalize=True))
     show_model_metrics(rForest, X_val, y_val)
    0.8626943005181347
    F1 score: [0.18461538 0.92503536]
    F1 score micro: 0.8626943005181347
    F1 score weighted: 0.8156987320892313
    Precision score: [0.75
                                 0.86507937]
    Recall score: [0.10526316 0.99392097]
[]: rForest = RandomForestClassifier(n_estimators=30)
     rForest.fit(X_train, y_train)
     y_pred = rForest.predict(X_val)
     print(accuracy_score(y_val, y_pred, normalize=True))
     show_model_metrics(rForest, X_val, y_val)
```

### 0.8626943005181347

F1 score: [0.23188406 0.92460882] F1 score micro: 0.8626943005181347 F1 score weighted: 0.8223152665001824 Precision score: [0.66666667 0.86898396] Recall score: [0.14035088 0.98784195]

Widzimy, że skuteczność modeli XGBoost i Random Forest dla różnych parametrów oscylowała niezmiennie wokół 85%, natomiast z racji niezbalansowania jest to wynik mocno zawyżony.

#### 1.4.5 DecisionTreeClassifier

Wstępne parametry i wpływ parametrów na predykcyjność


## Bez log

Train set scores F1 score: [0.47897623 0.94122499] F1 score micro: 0.8943661971830986 F1 score weighted: 0.8798887990025819 Precision score: [0.69312169 0.90952571] Recall score: [0.36592179 0.97521368] Validation set scores F1 score: [0.375 0.92774566] F1 score micro: 0.8704663212435233 F1 score weighted: 0.8461226002575699 Precision score: [0.65217391 0.88429752] Recall score: [0.26315789 0.97568389] []: cols = ["max\_depth", "AUC", "dataset"] history = pd.DataFrame(columns=cols)  $n_{depth} = np.arange(1,15,1)$ for depth in tqdm(n\_depth): dt = DecisionTreeClassifier(criterion='gini', max\_depth=depth).fit(X\_train,\_ →y\_train) train\_score = dt.score(X\_train,y\_train) val\_score = dt.score(X\_val,y\_val) history = history.append(dict(zip(cols, [depth, train\_score, "train"])), \_\_ →ignore\_index=True) history = history.append(dict(zip(cols, [depth, val\_score, "val"])), \_\_ →ignore\_index=True)

sns.lineplot(data=history, x = "max\_depth", y = "AUC", hue = "dataset")

0%| | 0/14 [00:00<?, ?it/s]

plt.show()




Wraz ze wzrostem głębokości drzewa, wzrasta AUC na zbiorze treningowym, ale spada na zbiorze walidacyjnym - model się przeucza.

```
cols = ["min_samples_split","AUC", "dataset"]
history = pd.DataFrame(columns=cols)

n_depth = np.arange(2,40,1)
for depth in tqdm(n_depth):
    dt = DecisionTreeClassifier(criterion='gini', min_samples_split=depth).
    fit(X_train, y_train)
        train_score = dt.score(X_train, y_train)
        val_score = dt.score(X_val, y_val)
        history = history.append(dict(zip(cols, [depth, train_score, "train"])),u
        ignore_index=True)
        history = history.append(dict(zip(cols, [depth, val_score, "val"])),u
        ignore_index=True)


sns.lineplot(data=history, x = "min_samples_split", y = "AUC", hue = "dataset")
plt.show()
```

0%| | 0/38 [00:00<?, ?it/s]



AUC zbioru walidacyjnego pozostaje na podobnym poziomie.

0%| | 0/38 [00:00<?, ?it/s]



AUC spada na zbiorze treningowym, ale rośne na walidacyjnym.

```
\mathbf{Z} \log
```

-----


Train set scores


F1 score: [0.47897623 0.94122499]
F1 score micro: 0.8943661971830986
F1 score weighted: 0.8798887990025819
Precision score: [0.69312169 0.90952571]
Recall score: [0.36592179 0.97521368]

-----


Validation set scores

F1 score: [0.36585366 0.92463768]
F1 score micro: 0.8652849740932642
F1 score weighted: 0.8421229420674474
Precision score: [0.6 0.88365651]
Recall score: [0.26315789 0.96960486]










```
[]: cols = ["min_samples_leaf", "AUC", "dataset"]
history = pd.DataFrame(columns=cols)
```

```
n_depth = np.arange(2,40,1)
for depth in tqdm(n_depth):
    dt = DecisionTreeClassifier(criterion='gini', min_samples_leaf=depth).

ifit(X_train_log, y_train_log)
    train_score = dt.score(X_train_log, y_train_log)
    val_score = dt.score(X_val_log, y_val_log)
    history = history.append(dict(zip(cols, [depth, train_score, "train"])),u
ignore_index=True)
    history = history.append(dict(zip(cols, [depth, val_score, "val"])),u
ignore_index=True)

sns.lineplot(data=history, x = "min_samples_leaf", y = "AUC", hue = "dataset")
plt.show()
```



Wnioski są analogiczne jak dla ramki bez zlogarytmowania.

**Predyktory po wstępnym doborze parametrów** Wybierzmy parametry, które dają nadzieję na najlepsza predykcyjność przy zachowanym jednocześnie nieprzetrenowanym modelu.

```
min_samples_leaf=30)
    dt_clf2.fit(X_train, y_train)
    print("----")
    print("Train set scores")
    show_model_metrics(dt_clf2, X_train, y_train)
    print("----")
    print("Validation set scores")
    show_model_metrics(dt_clf2, X_val, y_val)
   Train set scores
   F1 score: [0.44776119 0.93909465]
   F1 score micro: 0.8902891030392883
   F1 score weighted: 0.8738991804833832
   Precision score: [0.6741573 0.90555556]
   Recall score: [0.33519553 0.97521368]
   Validation set scores
   F1 score: [0.37974684 0.92929293]
   F1 score micro: 0.8730569948186528
   F1 score weighted: 0.8481423403047329
   Precision score: [0.68181818 0.88461538]
   Recall score: [0.26315789 0.9787234 ]
[]: dt_clf_log2 = DecisionTreeClassifier(criterion='gini',
                               max_depth=4,
                               min_samples_leaf=32)
    dt_clf_log2.fit(X_train_log, y_train_log)
    print("----")
    print("Train set scores")
    show_model_metrics(dt_clf_log2, X_train_log, y_train_log)
    print("-----")
    print("Validation set scores")
    show_model_metrics(dt_clf_log2, X_val_log, y_val_log)
   Train set scores
   F1 score: [0.44776119 0.93909465]
   F1 score micro: 0.8902891030392883
   F1 score weighted: 0.8738991804833832
```

Precision score: [0.6741573 0.90555556] Recall score: [0.33519553 0.97521368]

Validation set scores

F1 score: [0.37974684 0.92929293] F1 score micro: 0.8730569948186528 F1 score weighted: 0.8481423403047329 Precision score: [0.68181818 0.88461538] Recall score: [0.26315789 0.9787234]

Z powyższych wyników widać, że wszystkie wartości po doborze parametrów są lepsze, jednakże różnica nie jest znacząca.

## 1.4.6 Wnioski

Jak widać, mimo dość wysokich wyników metryk ważonych, nasz model dość przeciętnie radzi sobie z jego głównym zadaniem - wykrywaniem pacjentów, którzy zmarli. Będzie to naszym priorytetem na dalszym etapie prac. Jeśli chodzi o ramkę z danymi poddanymi transformacji logarytmicznej, nie zmienia to niemal w ogóle wyników modelu.